Case – Engenharia de Dados

Construção de uma dimensão de pessoas (dim_pessoa) a partir de múltiplas fontes, com controle de qualidade, deduplicação e histórico (SCD Tipo 2).

Tecnologias: Databricks | Parquet | PostgreSQL

Problema Proposto

Problema

- Os dados estavam distribuídos em múltiplas fontes:
- RH (folha)
- eSocial
- Sistema de gestão

Desafio

- Dados duplicados e inconsistentes
- Divergência entre fontes
- Falta de histórico confiável
- Ausência de visão única de pessoa

Arquitetura de Dados Proposta

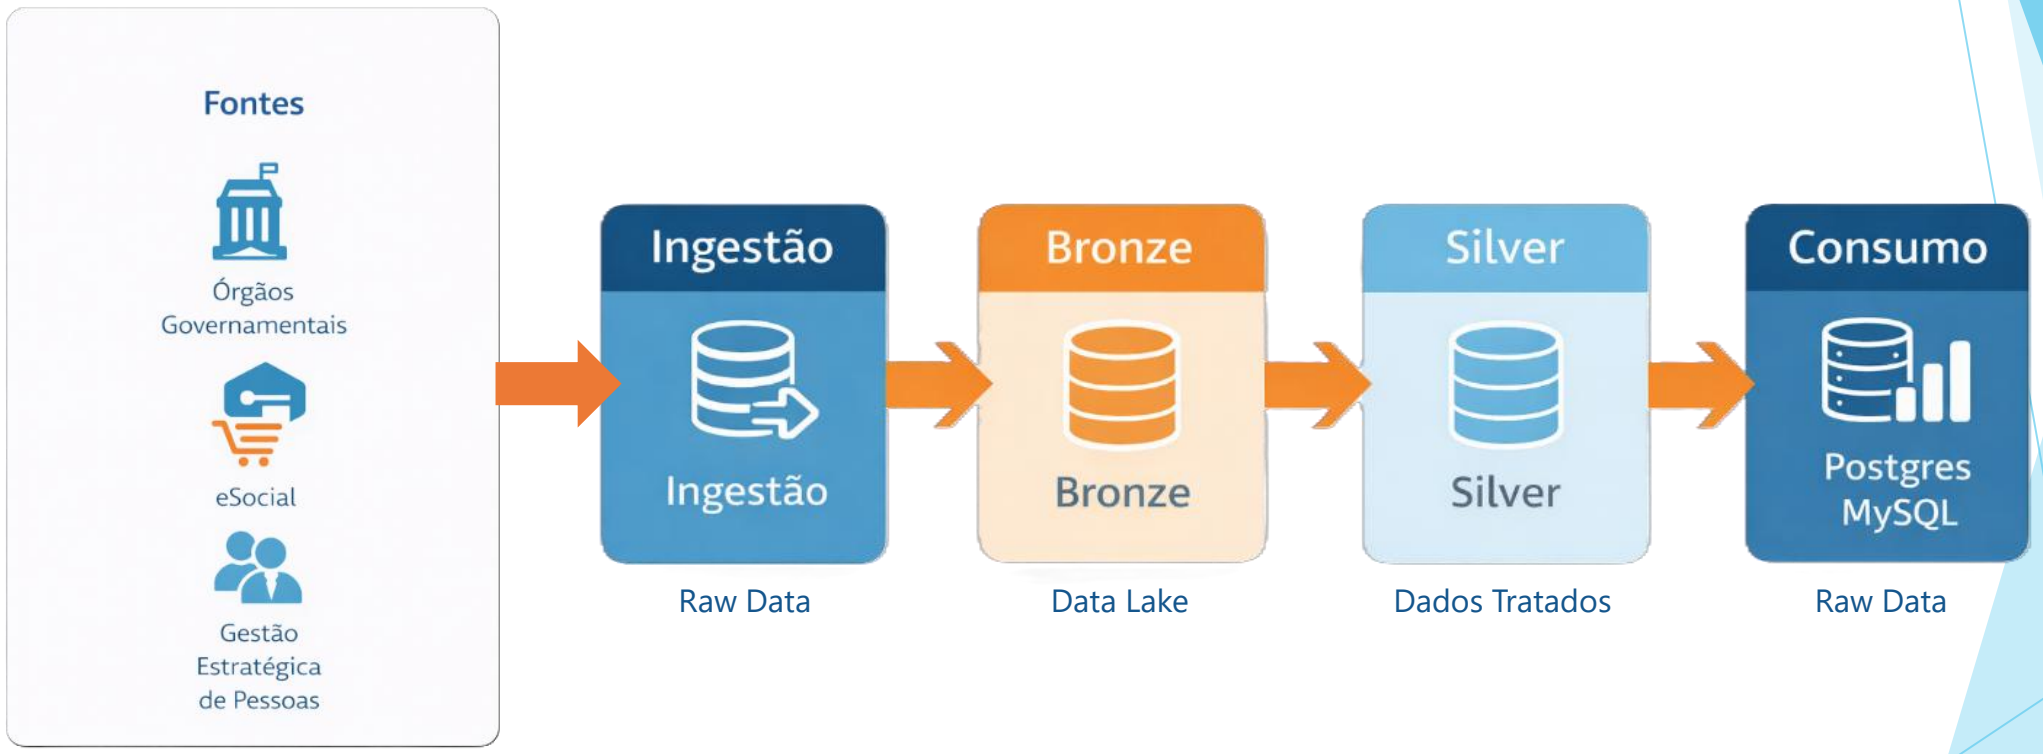

Evolução para Cloud

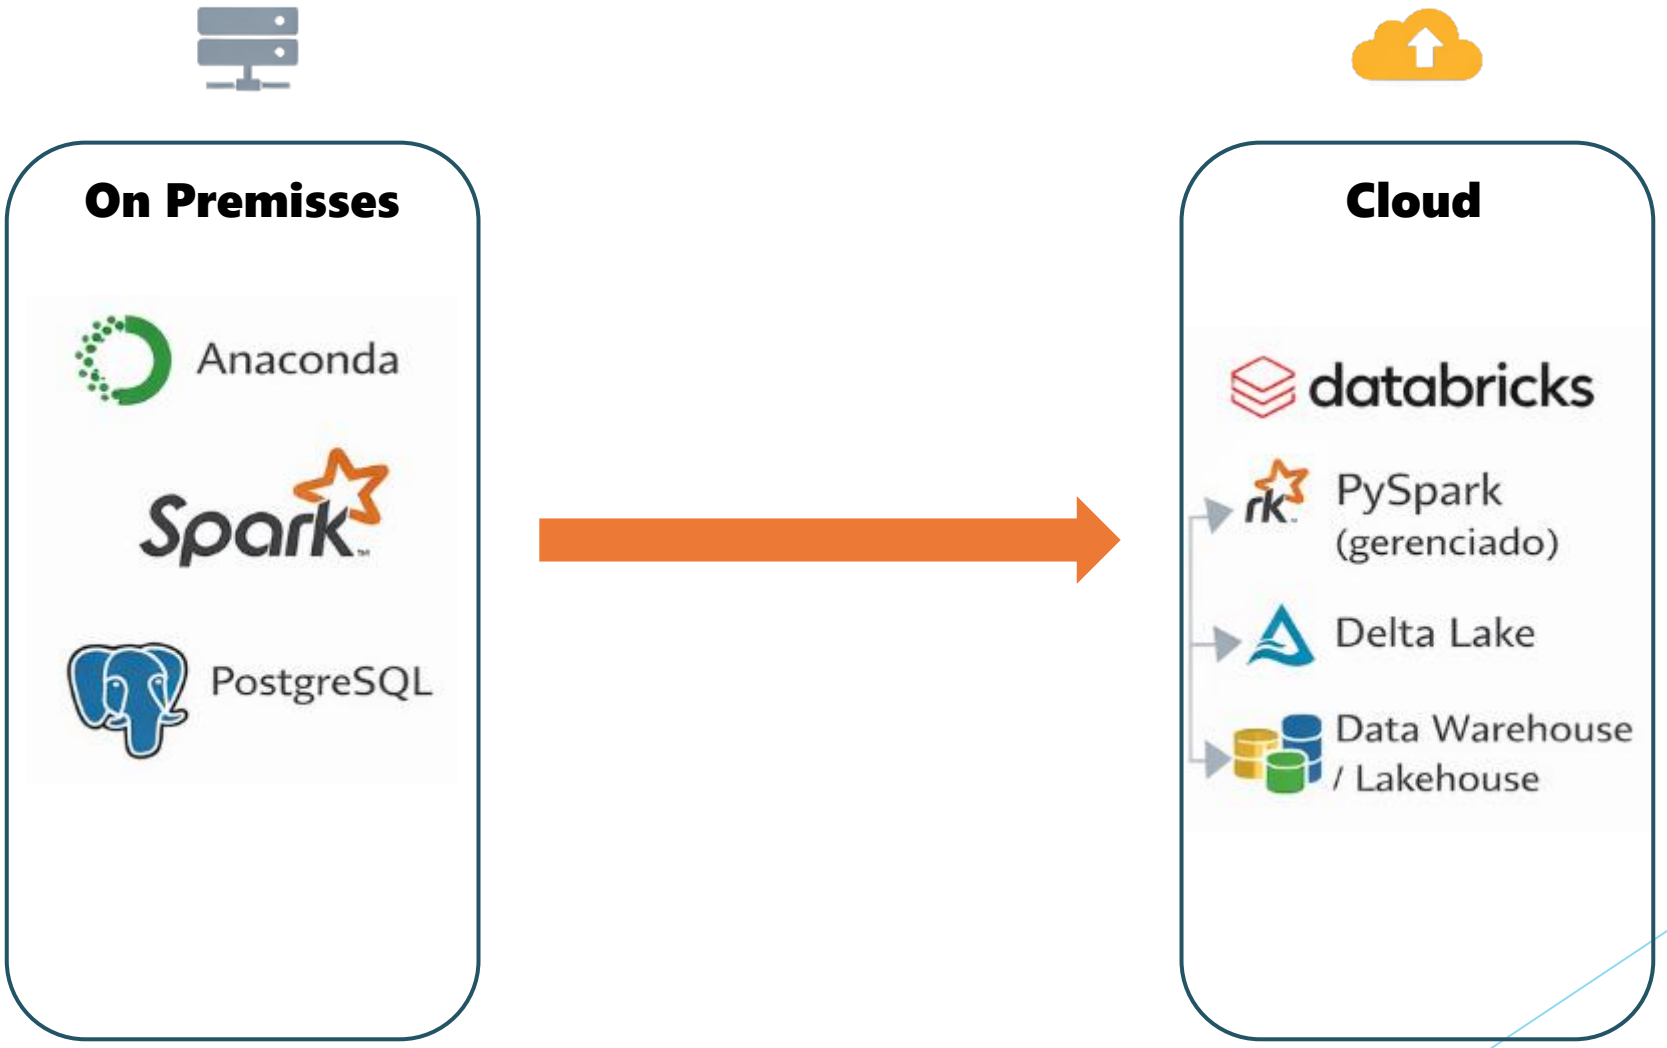

Tecnologias aplicáveis e funcionamento

❑ Arquiterura On Premisses

- Anaconda (ambiente local)
- PySpark (processamento distribuído)
- PostgreSQL (armazenamento relacional)

❑ Limitações

- Ambiente controlado para desenvolvimento e testes
- Adequado para cenários com restrições de dados sensíveis
- Facilidade de implementação e validação local
- Limitações Identificadas
- Escalabilidade limitada
- Dependência de infraestrutura local
- Necessidade de ferramentas adicionais para orquestração (ex: Airflow)

Tecnologias aplicáveis e funcionamento

❑ Sugestão de Arquitetura Cloud

- Databricks (plataforma de processamento gerenciado)
- PySpark (processamento distribuído escalável)
- Delta Lake (armazenamento otimizado e versionado)
- Cloud Storage (S3 / ADLS / GCS)

❑ Benefícios esperados

- Escalabilidade sob demanda
- Processamento distribuído gerenciado
- Redução de overhead operacional
- Suporte a pipelines incrementais (MERGE / UPSERT)

Resultado Esperado

❑ Dimensão Pessoa:

- dim_pessoa_histórica

  rastreia todas as mudanças

- dim_pessoa_atual

  1 registro por CPF - consumo analítico

- Armazenamento:
- Parquet particionado (is_current)
- PostgreSQL (Ou MySQL)